



민감도 지표와 머신러닝을 활용한 공압 밸브 구동기 성능저하 예측 연구

A Study on Performance Degradation Prediction of Pneumatic Valve Actuators Using Sensitivity Indicators and Machine Learning



최희재¹, 장영아¹, 고진욱[†]

¹국립한밭대학교 컴퓨터공학과, [†]국립한밭대학교 소프트웨어중심대학사업단

1. Introduction

- 공압 밸브 구동기는 시스템의 제어 안정성과 운전 효율에 직접적인 영향을 미치는 핵심 구성요소이다.
- 구동기의 상태를 정량적으로 평가하고 예측하는 기술은 스마트 플랜트 구축을 위한 상태 기반 진단과 예지보전을 위한 핵심이다.
- 본 연구에서는 공압 밸브 구동기의 성능 저하를 조기에 예측하고, 장기적인 열화 추세를 정량적으로 진단하기 위한 머신러닝 기반 FDD(Fault Detection & Diagnostics) 접근법을 제안한다.

2. Background

- 원전 및 플랜트 산업에서는 구동기 성능 저하가 제어 불능 및 사고로 이어질 수 있어, 조기 진단 기술이 필수적이다.
- 기존의 물리 시험 및 단순 보정(auto-calibration) 방식은 복잡한 운전 환경에서의 비선형 거동과 미세 이상을 충분히 반영하지 못하였다.
- 또한, 운전 조건 변화에 따른 동특성 전반을 포괄적으로 설명하기에 어려움이 존재한다.
- 따라서 본 연구는 기존의 auto-calibration 중심 접근을 넘어, 물리 파생특성(민감도, 지표값)을 데이터 전처리 과정에 도입하여 데이터의 물리적 일관성과 해석 가능성을 강화하였다.

3. Methods

1. 데이터 수집

- 실제 제어 밸브 운전 조건을 모사한 실험 장치를 구성하였다.
- 밸브 구동압력 변화에 따른 행정거리, 추력 등 약 30만 개의 운전 데이터를 취득하였다.
- 또한 급수 제어 계통의 운전 모사를 통해 다양한 압력·유량 조건을 반영한 복합 데이터셋을 구축하였다.



Fig. 1 실험 데이터셋 수집에 사용된 계측 장치

Symbol	Description	Specification (S/N)
V_1	Pressure Vessel (3 m^3 , 10 bar)	-
P_1	Valve Inlet Pressure, bar	SENSYS (040412D051)
P_2	Valve Outlet Pressure, bar	SENSYS (040412D051)
Q	Valve Outlet Flowrate, LPM	Dongyang (DY-LWGY-80C)
LVDT	Valve Opening Rates, %	KOMEIN (01708220005)
DAQ	Data Acquisition System, 32 ch.	YOKOGAWA (SSN808730)

Table 1 수집된 데이터 종류

2. 데이터 전처리

- 신호 필터링과 보간(interpolation)을 통한 노이즈 및 결측치를 보정하고, 정규화를 수행하여 모델 학습의 안정성을 확보하였다.
- 민감도(sensitivity) 및 지표값(index value)과 같은 물리 파생 특성을 도입하여 데이터의 물리적 일관성과 해석 가능성을 강화하였다.

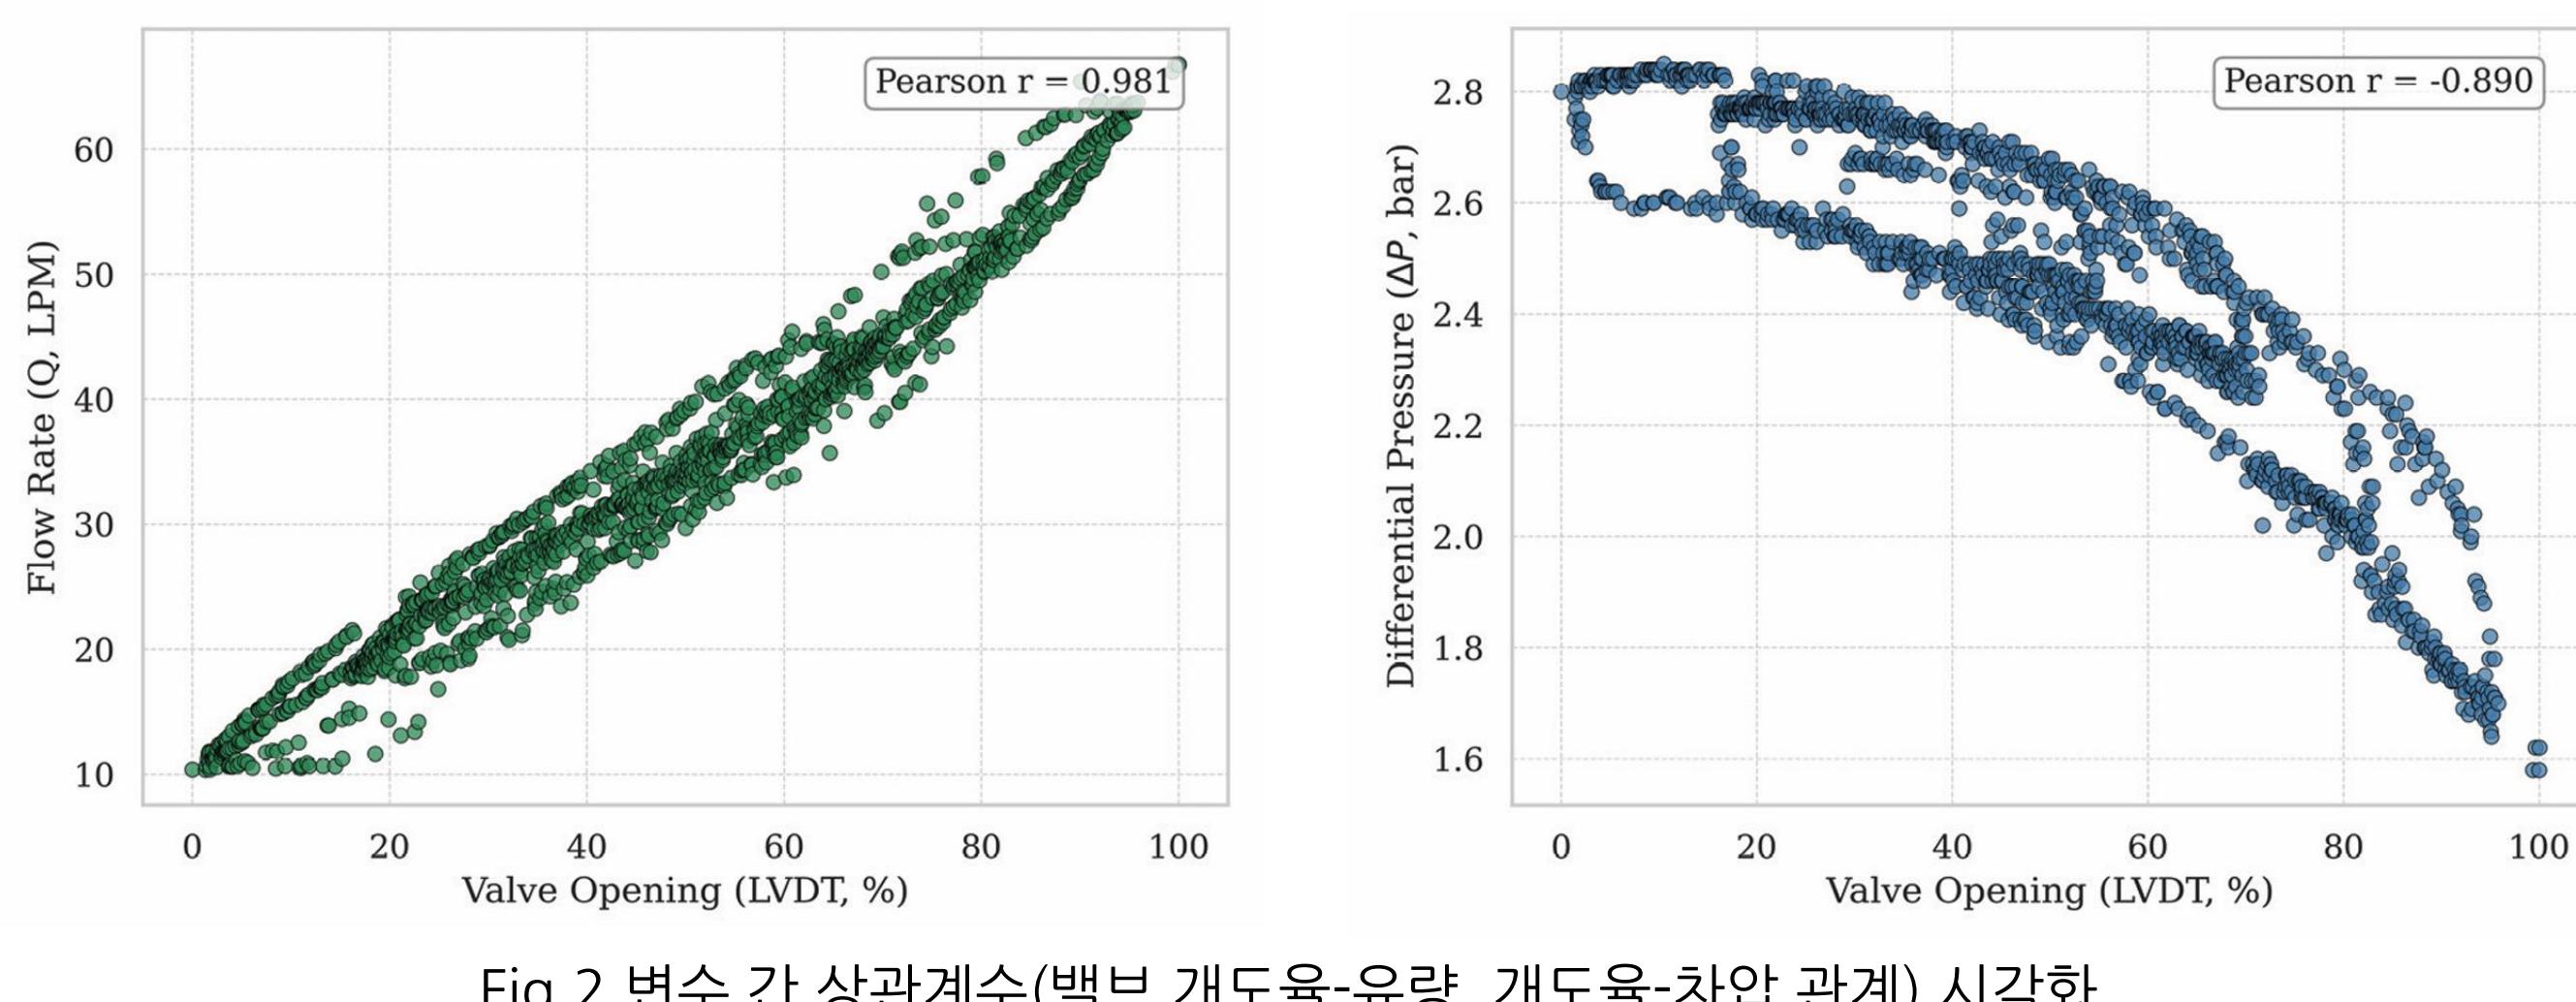


Fig. 2 변수 간 상관계수(밸브 개도율-유량, 개도율-차압 관계) 시각화

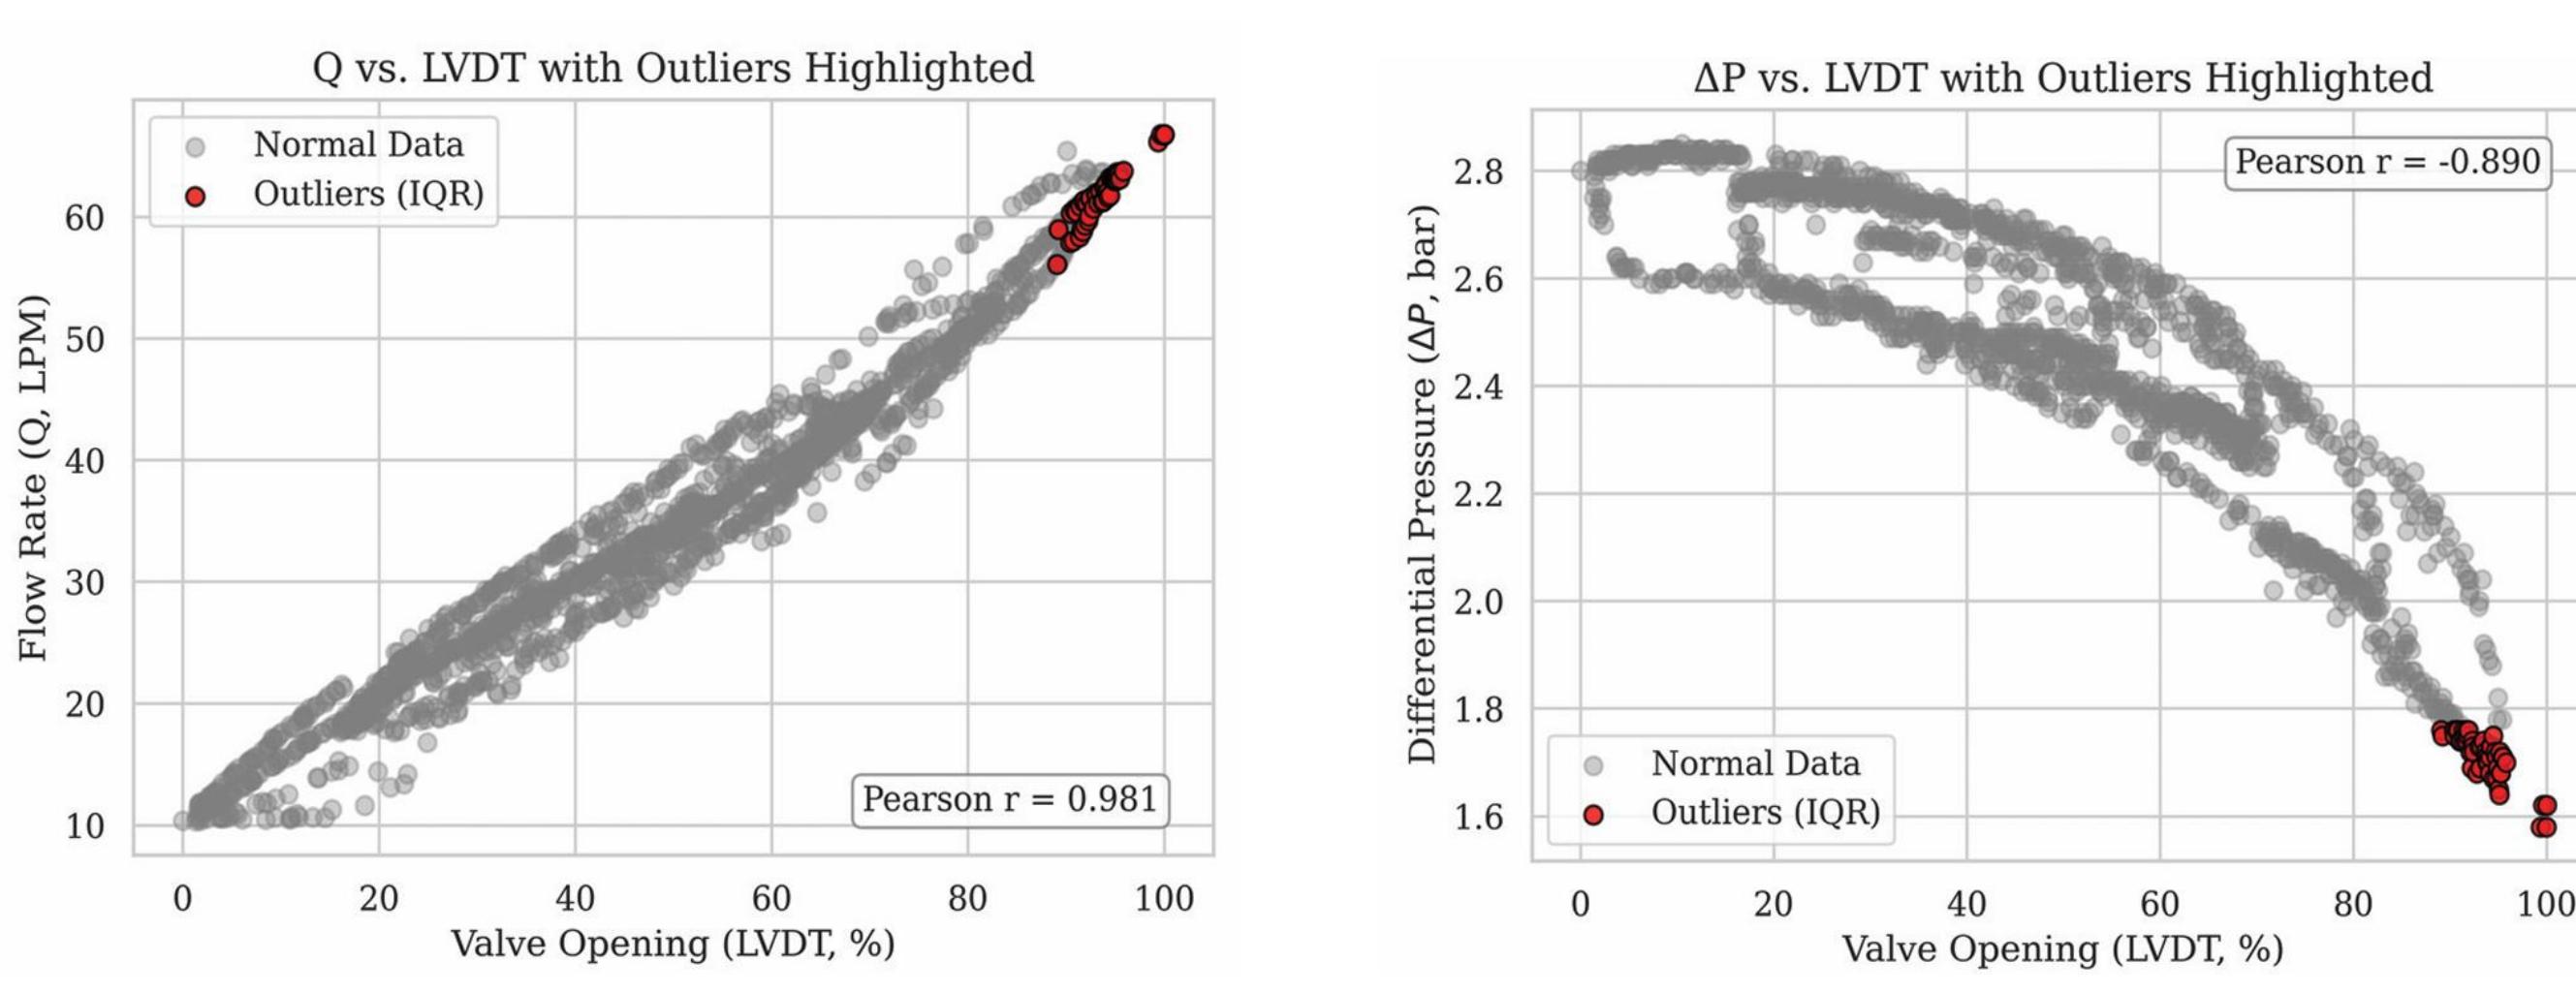


Fig. 3 이상치 제거 후 데이터 분포

$$\text{Lower Bound} = Q_1 - 1.5 \times IQR$$

$$\text{Upper Bound} = Q_3 + 1.5 \times IQR$$

Fig. 4 이상치 판단 조건식

References

- [1] 고진욱, 김홍집. “원자력발전소 유량제어계통에서 머신러닝 기반 신호예측에 관한 연구”, 한국유체기계학회 논문집, 제28권, 제4호, pp.29-36, 2025.

3. 학습모델 설계

- 예측 모델은 랜덤포레스트와 다층 퍼셉트론을 조합한 양상별 구조를 활용하였다.
- 하이퍼파라미터 최적화를 통해 예측 정확도와 일반화 성능을 향상시켰다.
- 특정 데이터 분할에 의존하는 편향을 보완하기 위해 k-fold 교차검증을 적용하였다.
- 전체 데이터를 5개 폴드로 나누어 20%의 검증 데이터와 80%의 훈련데이터를 총 10번 반복하여 예측하였다.

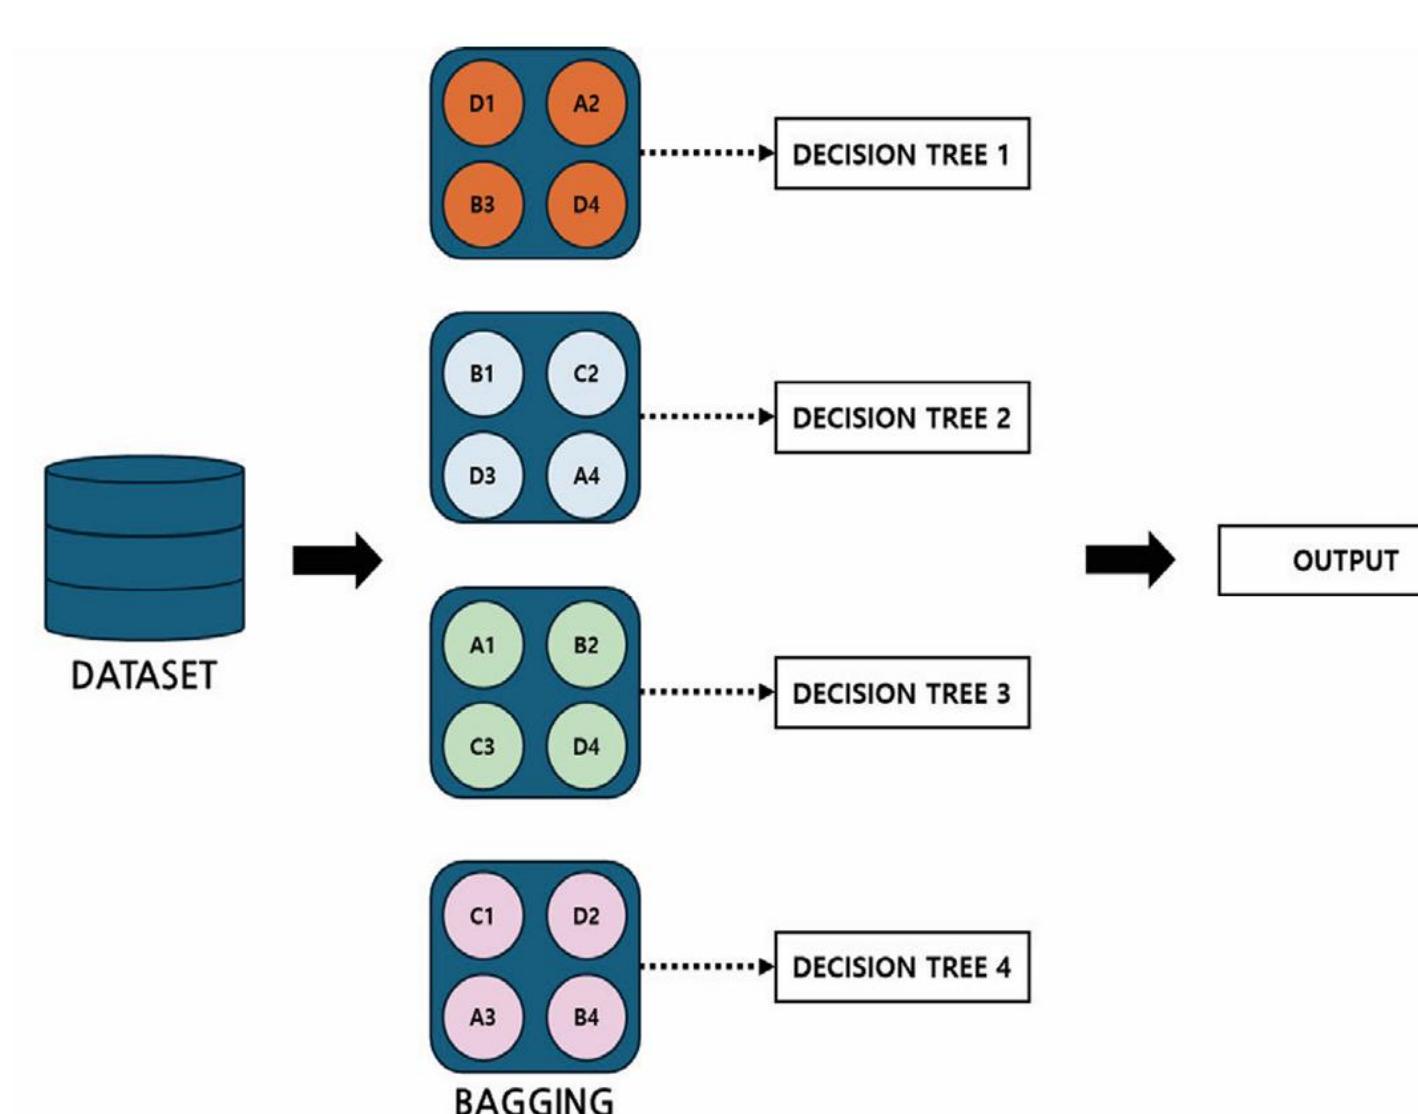


Fig. 5 랜덤포레스트에서의 배깅 과정

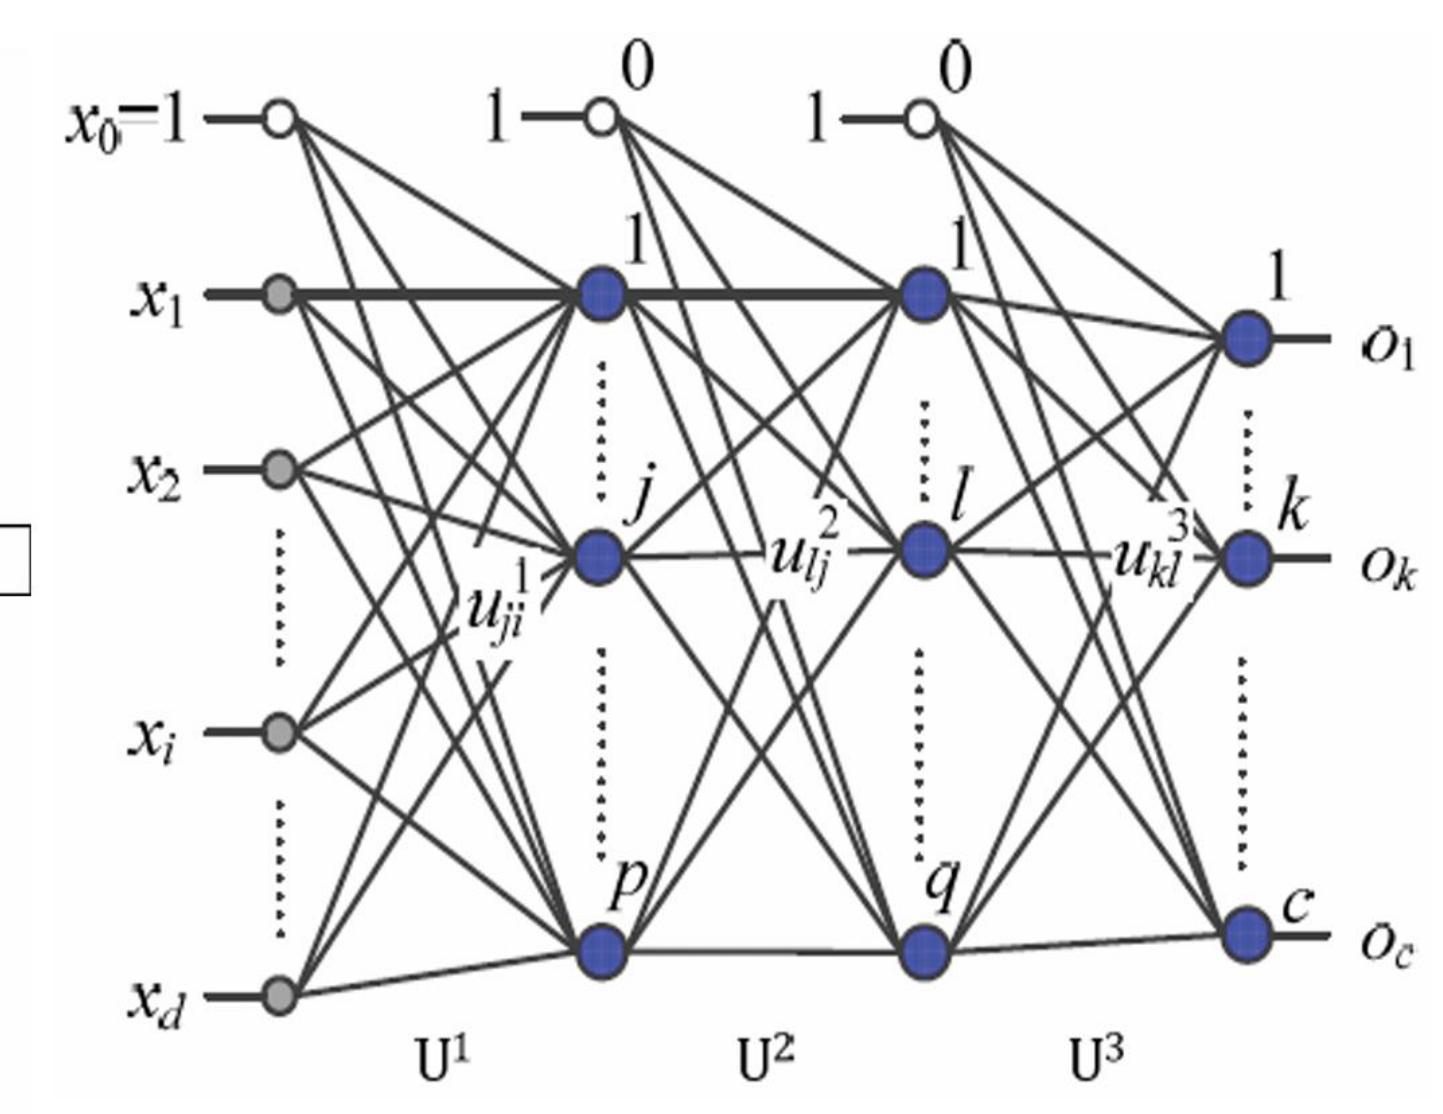


Fig. 6 3층 퍼셉트론의 구조

Input Feature	Random Forest		MLP		MLP + RepeatKFold		MLP + RepeatKFold + Hyperparameter Tuning	
	MSE	R ²	MSE	R ²	MSE	R ²	MSE ± CI	R ² ± CI
LVDT	7.8143	0.8434	0.0070	0.8749	0.0068	0.8745	0.0063±0.0011	0.8833±0.0120
Q	41.9686	0.7312	0.0137	0.7556	0.0133	0.7544	0.0124±0.0017	0.7708±0.0158

Table 2 입력 특성(LVDT, Q)을 기반으로 한 예측 모델의 최적화 진행 과정

4. 머신러닝 기반 FDD 접근

- 제안한 FDD(Fault Detection & Diagnostics) 기법은 구동기 상태를 정상/경미 저하/중증 저하의 3단계로 구분한다.
- 이를 통해 구동기 열화 상태를 조기에 감지하고, 물리적으로 해석 가능한 결과를 도출하였다.

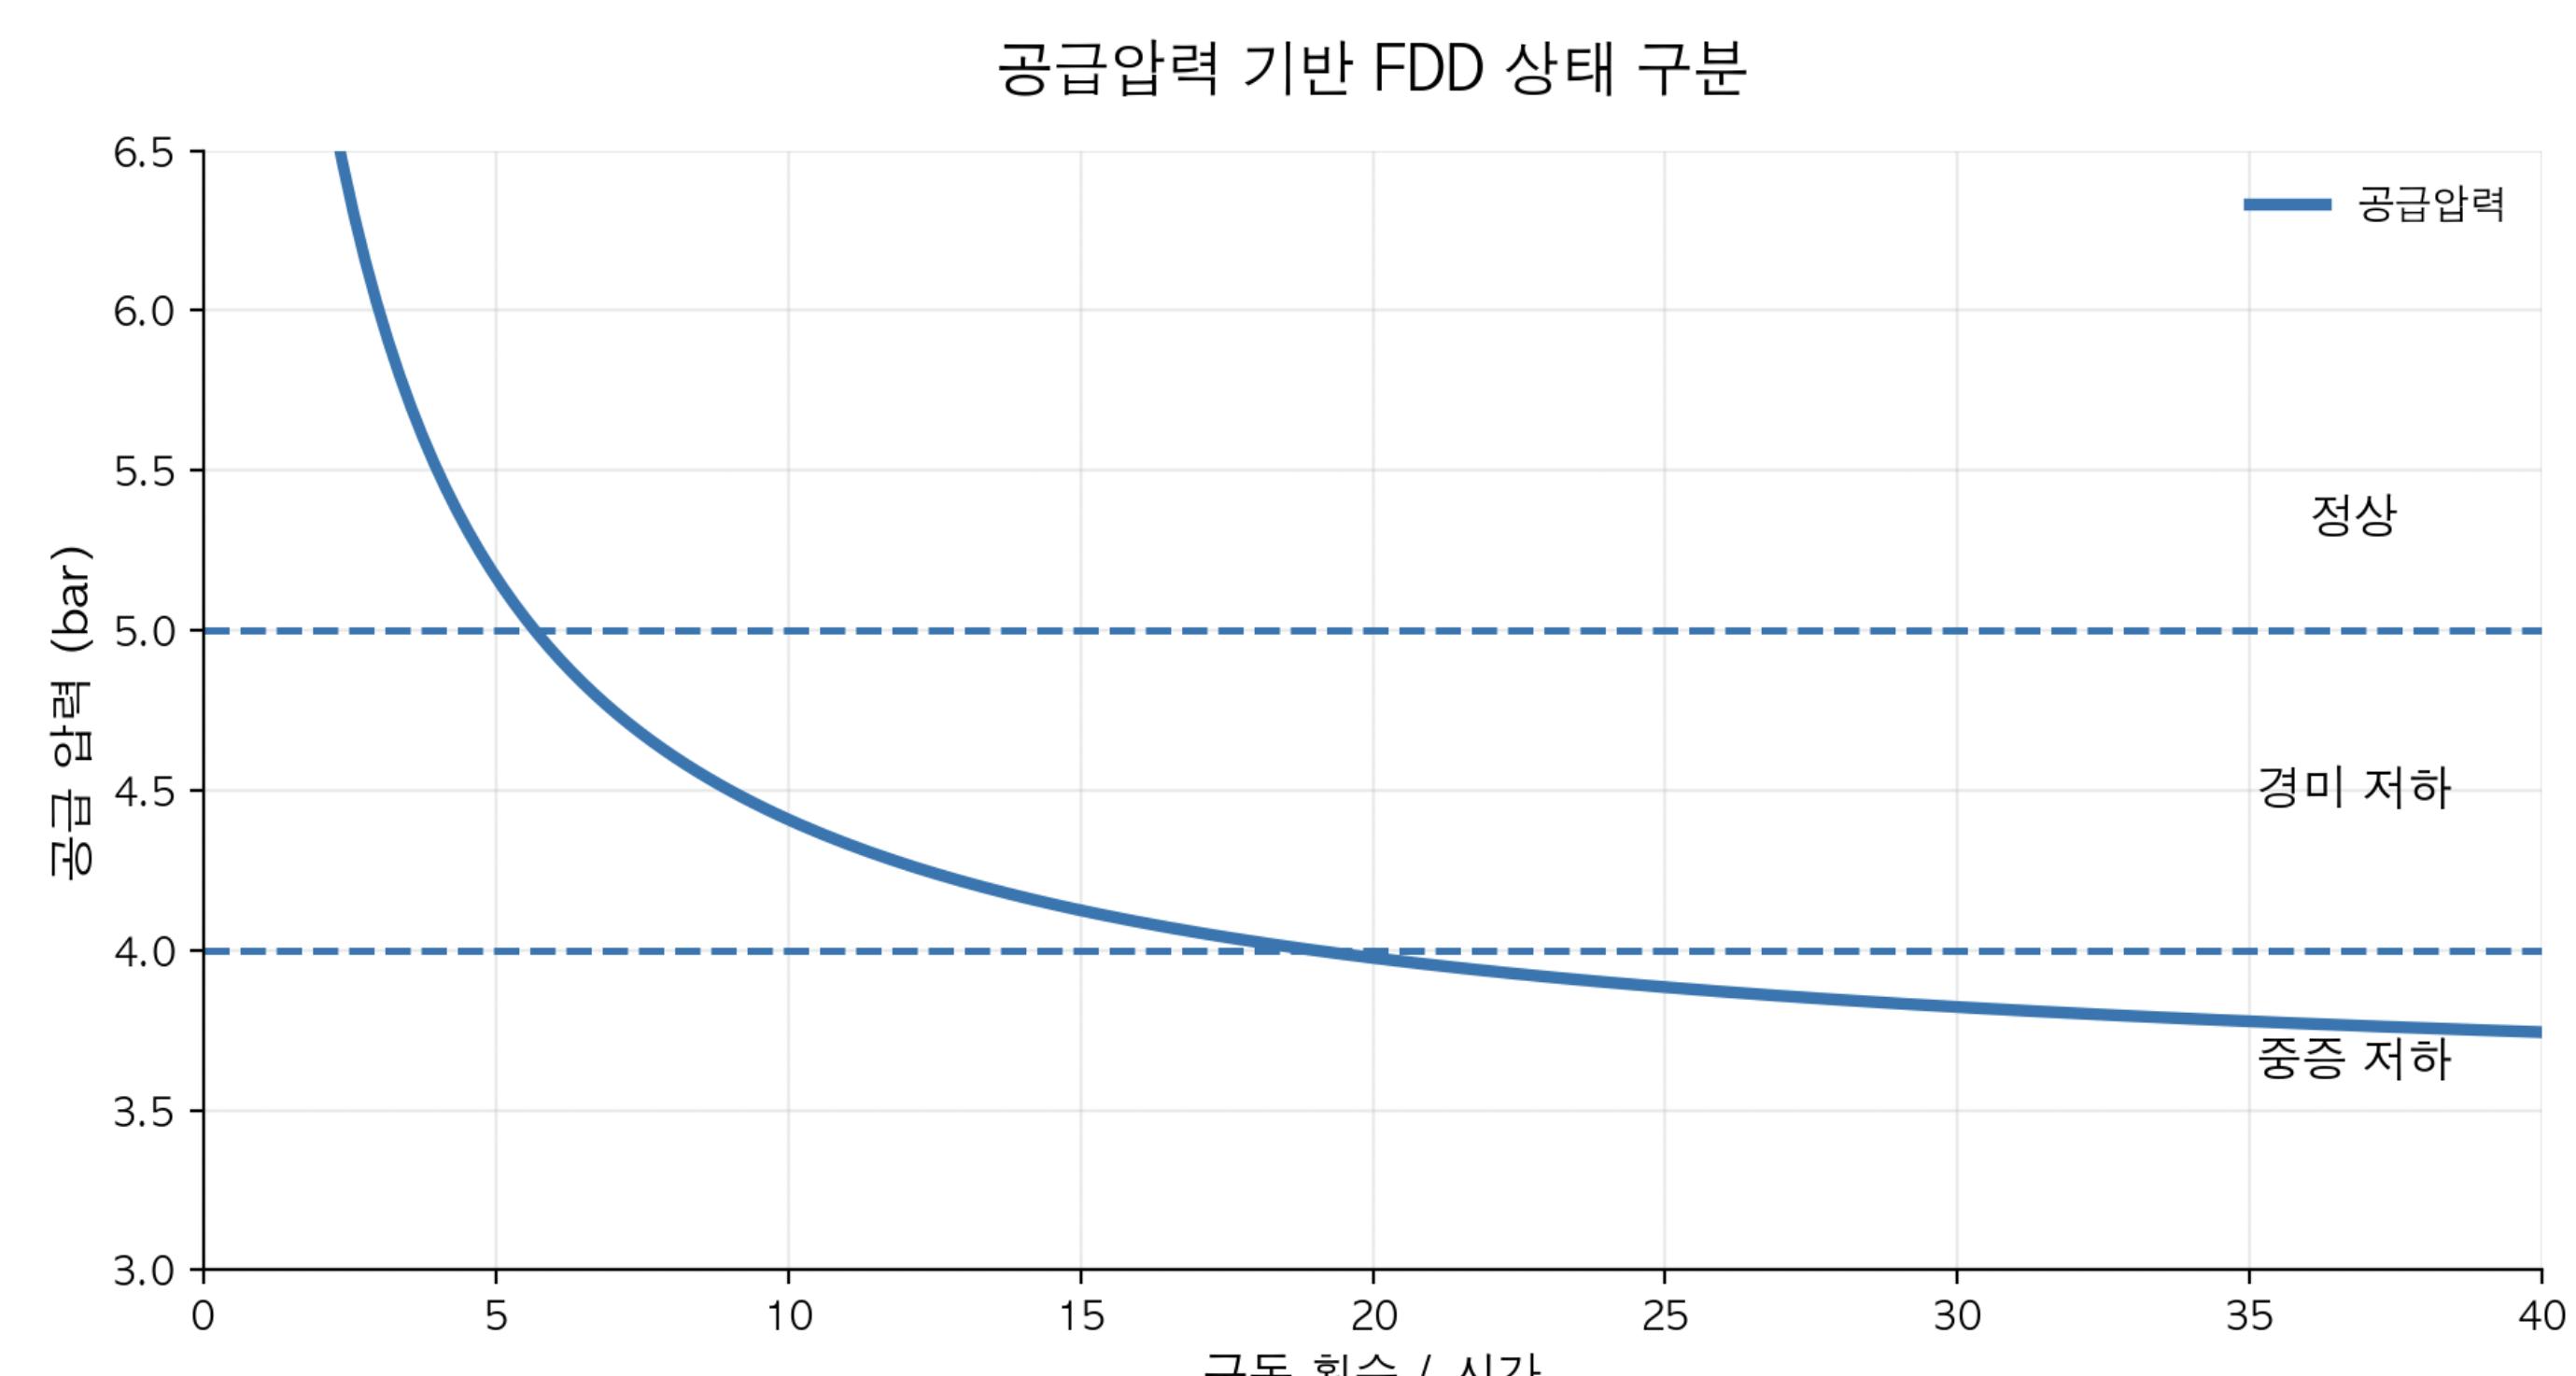


Fig. 7 FDD 상태 구분

4. Conclusion

- 본 연구는 기존의 단순 자가진단/보정 방식을 넘어, 구동기의 성능 저하를 조기에 예측하기 위해, 물리 모델과 머신러닝을 융합하여 데이터 기반 FDD 기법을 제시하였다.
- 향후 시계열 딥러닝 모델을 결합하여 잔여수명 예측으로 확장함으로써, 스마트 플랜트 환경에서 실시간 예지보전 모듈로 발전시킬 계획이다.

Acknowledgement

“본 연구는 2025년 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업의 연구결과로 수행되었음”(2022-0-01068)